

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ЛИПЕЦКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

Институт компьютерных наук

Кафедра автоматизированных систем управления

Лабораторная работа №1

по дисциплине

«Нейронные сети и глубокое обучение»

Студент М-РИТ-25-1 _____ Станиславчук С.М.

Руководитель

Профессор _____ Седых И.А.

Липецк, 2026

Содержание

1. Выдача задания 3

2. Ход работы 3

   2.1 ReLU + ReLU 3

   2.2 ReLU + Tanh 5

   2.3 ReLU + Sigmoid 7

3. Вывод 9

1. Выдача задания

В рамках лабораторной работы поставлена задача обучения многослойного перцептрона с алгоритмом обратного распространения ошибки.

Вариант 17: Функция

```
import numpy as np
np.random.seed(17)
X = np.random.uniform(0, 4*np.pi, 600).reshape(-1, 1)
y = np.sin(X) + 0.3*np.sin(5*X) + np.random.normal(0, 0.1, X.shape)
```

Активация скрытых слоев: ReLU; архитектура: Вход(1) -> 64 -> 32 -> Выход(1, Linear)

2. Ход работы

В качестве метрики определяющей точность использую MSE. Скорость обучения для всех функций активации постоянна = 0.02

2.1. ReLU + ReLU

```
epoch 0, loss 1.136373
epoch 200, loss 0.215445
epoch 400, loss 0.169322
epoch 600, loss 0.162735
Test MSE: 0.18996727415942807
```

График потерь и сравнения ReLU + ReLU приведены на рис. 1, 2.

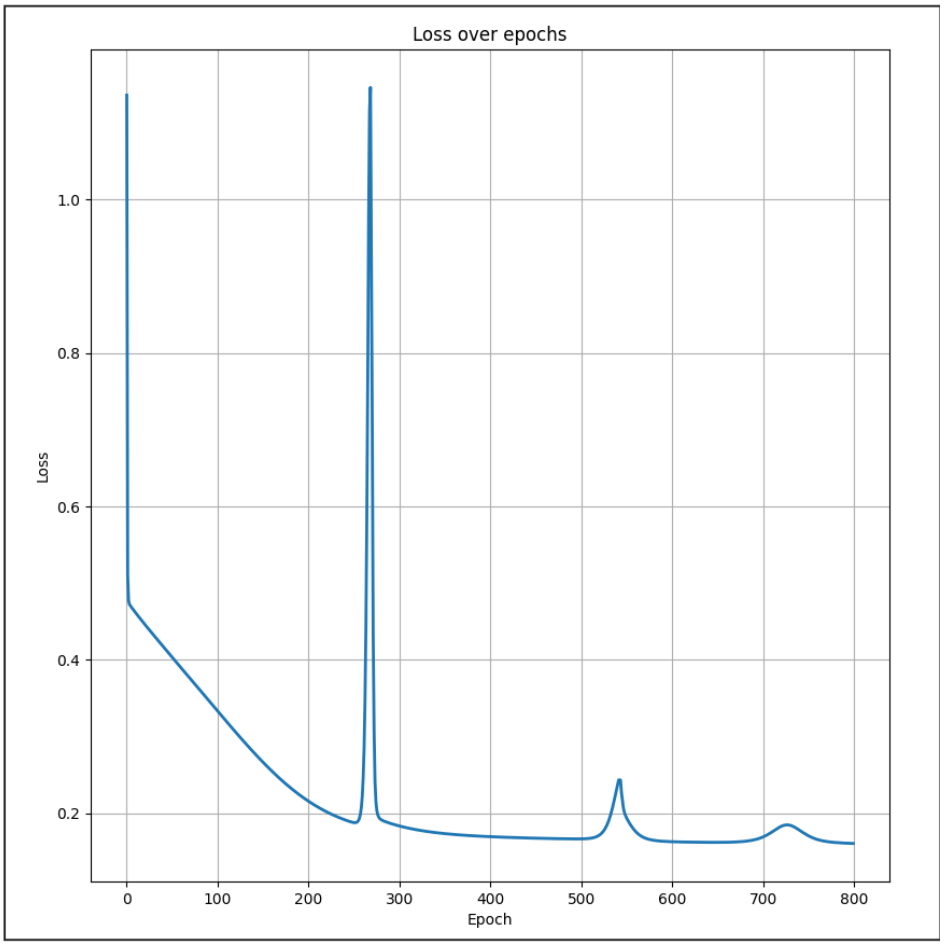


Рисунок 1 — Потери (ReLU + ReLU)

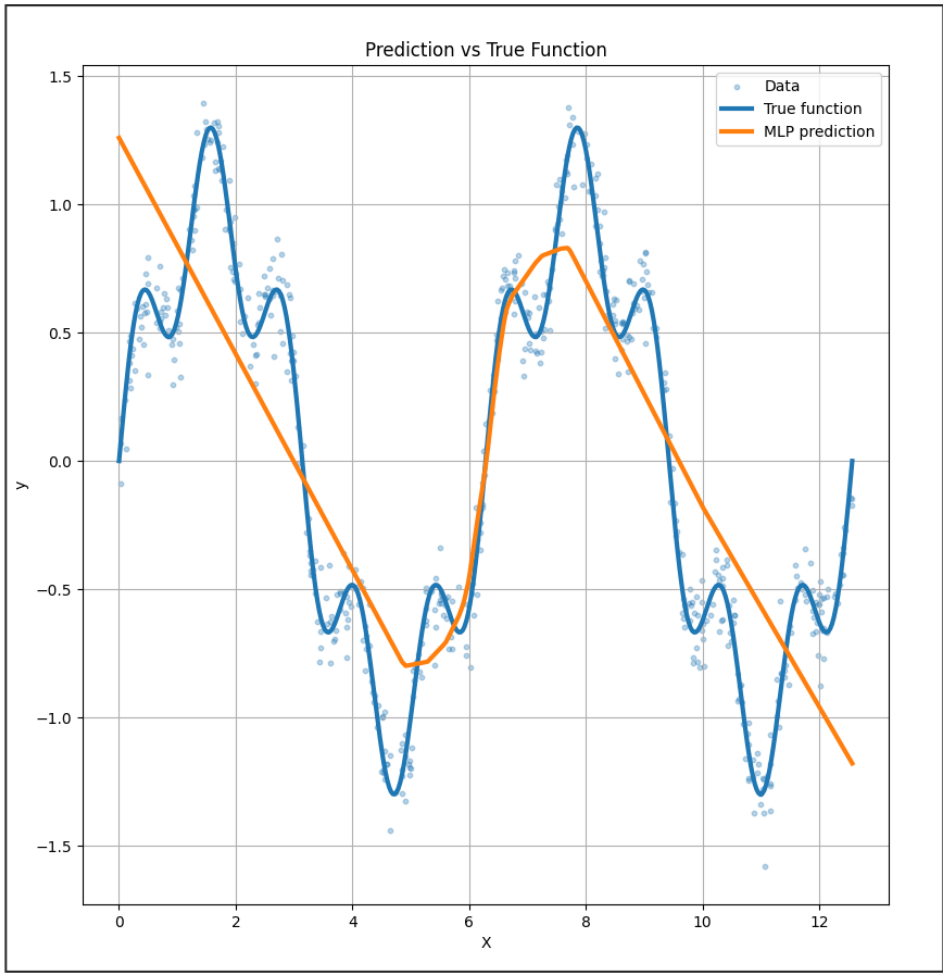


Рисунок 2 — Сравнение с исходной (ReLU + ReLU)

2.2. ReLU + Tanh

```
epoch 0, loss 0.645922
epoch 200, loss 0.131175
epoch 400, loss 0.121557
epoch 600, loss 0.116986
Test MSE: 0.1320729197341313
```

График потерь и сравнения ReLU + Tanh приведены на рис. 3, 4.

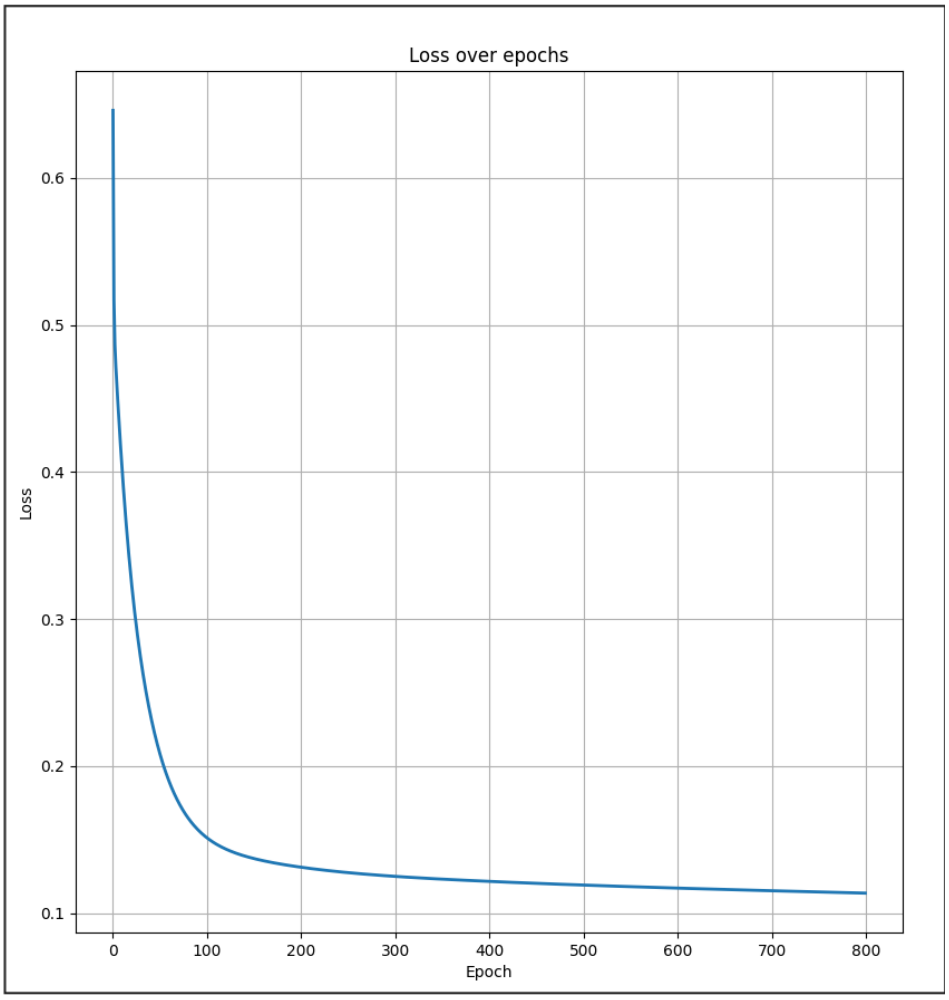


Рисунок 3 — Потери (ReLU + Tanh)

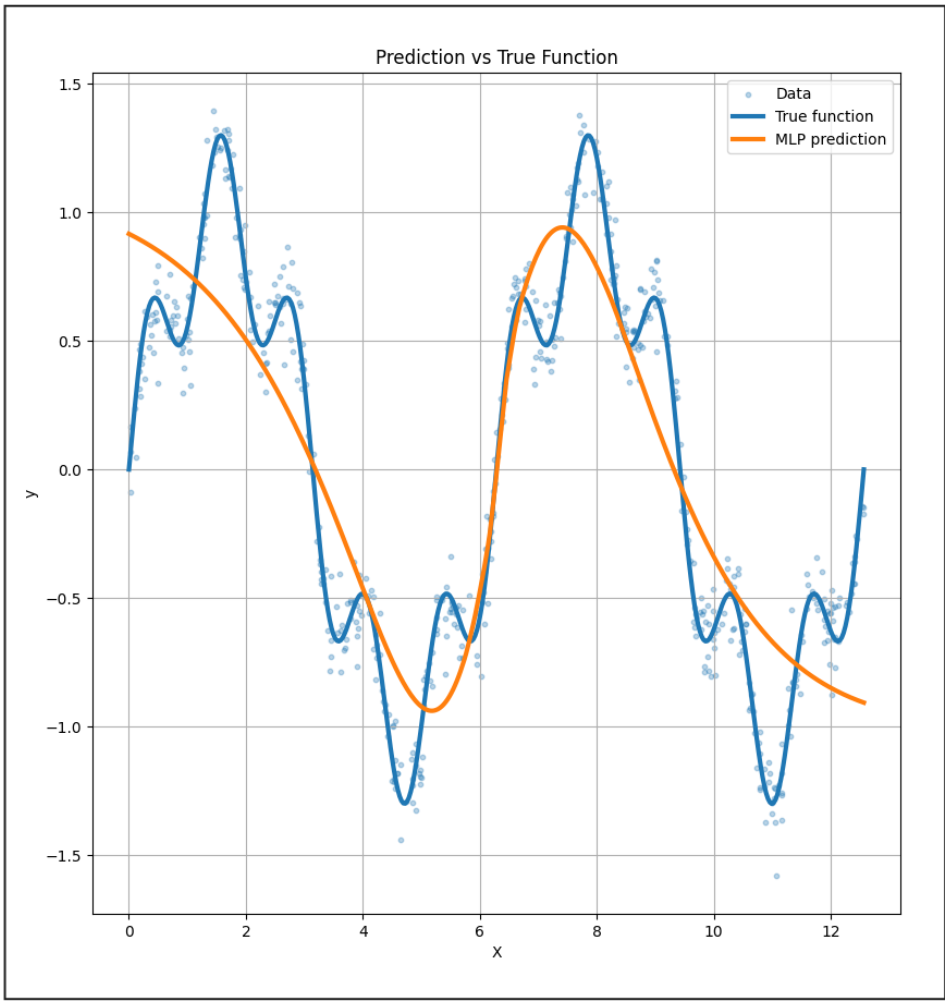


Рисунок 4 — Сравнение с исходной (ReLU + Tanh)

2.3. ReLU + Sigmoid

```
epoch 0, loss 0.662178
epoch 200, loss 0.431442
epoch 400, loss 0.323692
epoch 600, loss 0.219722
Test MSE: 0.1567918362202583
```

График потерь и сравнения ReLU + Sigmoid приведены на рис. 5, 6.

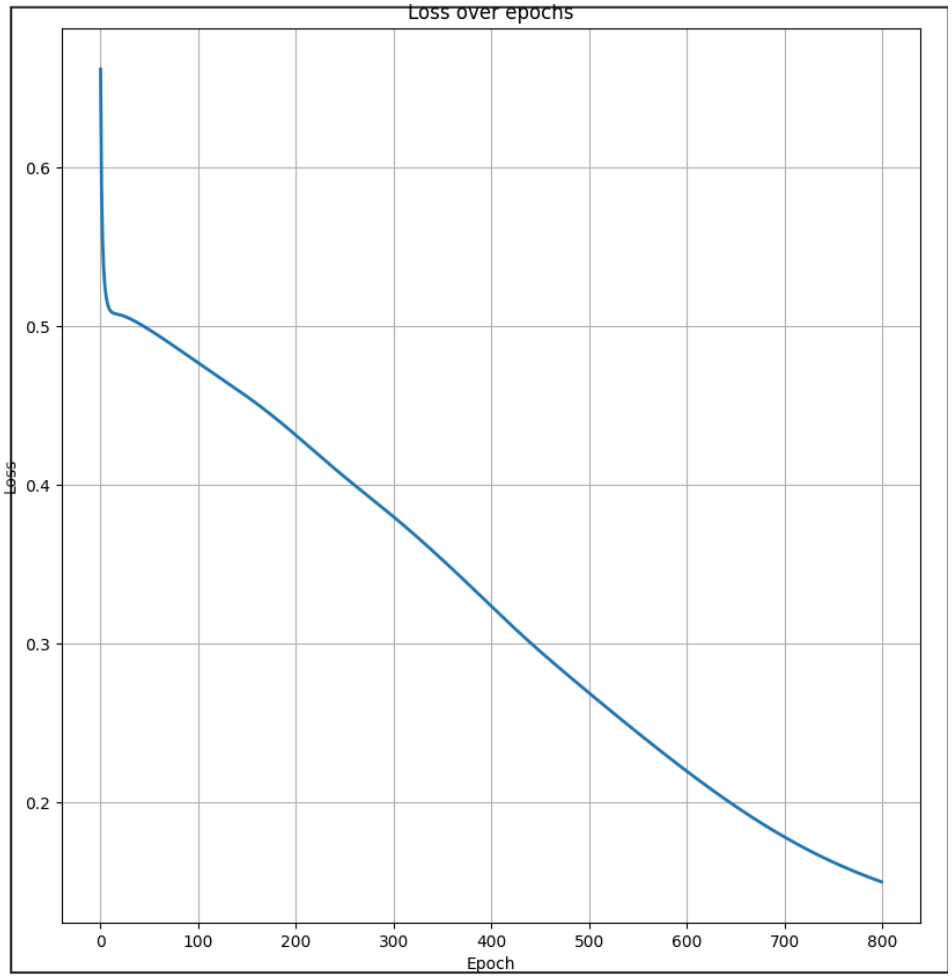


Рисунок 5 — Потери (ReLU + Sigm)

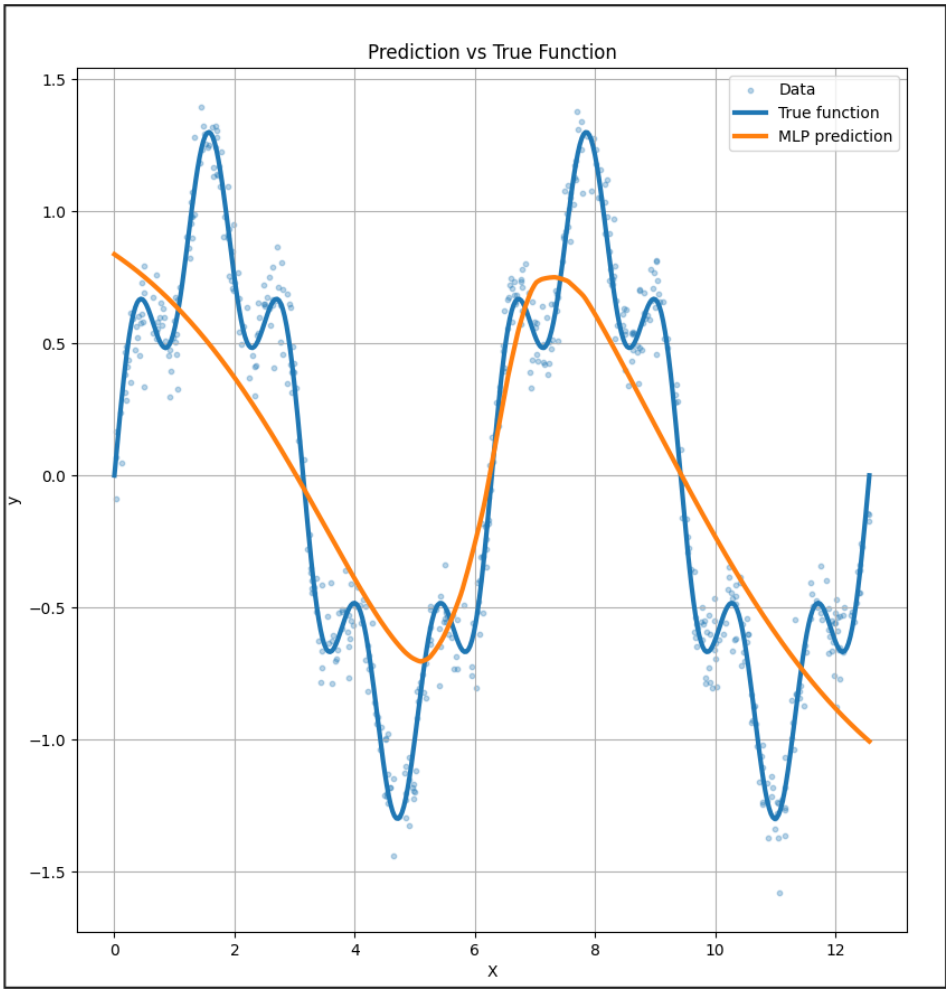


Рисунок 6 — Сравнение с исходной (ReLU + Sigm)

3. Вывод

В ходе лабораторной работы была проведена сравнительная оценка трёх конфигураций многослойного перцептрона, различающихся выбором функций активации: ReLU+ReLU, ReLU+Tanh и ReLU+Sigmoid. Целевая функция представляла собой суперпозицию синусоид, что накладывает требования на способность модели аппроксимировать гладкие, знакопеременные и периодические зависимости.

Результаты обучения показали, что наилучшее качество аппроксимации достигается при использовании комбинации ReLU на первом скрытом слое и гиперболического тангенса на втором. Это объясняется

тем, что функция ReLU эффективно выполняет первичное преобразование признаков, формируя кусочно-линейное представление входного пространства без эффекта насыщения в положительной области. В свою очередь, функция Tanh является симметричной относительно нуля и обладает гладкой нелинейностью, что позволяет корректно моделировать знакопеременную природу целевой функции и её кривизну.

Конфигурация ReLU+ReLU показала худшие результаты, несмотря на стабильное снижение функции потерь. Это связано с тем, что композиция функций ReLU формирует исключительно кусочно-линейное приближение. Для аппроксимации периодических функций в таком случае требуется значительно большее число нейронов, поскольку модель вынуждена воспроизводить гладкую кривую через ломаную структуру.

Использование сигмоидальной функции активации во втором слое (ReLU+Sigmoid) также привело к ухудшению качества обучения. Основной причиной является эффект насыщения сигмоиды, при котором производная функции стремится к нулю на больших по модулю значениях аргумента. Это приводит к затуханию градиентов и замедлению процесса оптимизации. Дополнительно сигмоида не является симметричной относительно нуля, что усложняет моделирование знакопеременных зависимостей.

Таким образом, комбинация ReLU и Tanh обеспечивает наиболее адекватное соответствие архитектуры сети свойствам целевой функции. ReLU формирует базовое представление данных, тогда как Tanh обеспечивает необходимую нелинейность для аппроксимации гладких колебательных процессов. Полученные результаты согласуются с теоретическими представлениями о влиянии функций активации на выразительную способность нейронных сетей и динамику их обучения.