

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ЛИПЕЦКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

Институт компьютерных наук

Кафедра автоматизированных систем управления

Лабораторная работа №2

по дисциплине

«Нейронные сети и глубокое обучение»

Студент М-РИТ-25-1 _____ Станиславчук С.М.

Руководитель

Профессор _____ Седых И.А.

Липецк, 2026

Содержание

1. Введение 3

2. Методология 3

3. Результаты экспериментов 4

   3.1 SGD 4

   3.2 Momentum SGD 5

   3.3 Adam 6

4. Важность каналов 7

5. Сравнение оптимизаторов 7

6. Вывод 8

1. Введение

В данной работе исследуется влияние использования двухканального входа (исходное изображение + градиенты по краям) на обучение сверточной нейронной сети. Задача состоит в классификации изображений размером $28 \times 28 \times 1$. Архитектура (Вариант 17) имеет следующий вид:

Архитектура: - Вход 1 (оригинал, 28x28x1) -> Conv2D (1->8, 3x3, padding: 1) -> ReLU - Вход 2 (градиенты Sobel, 28x28x1) -> Conv2D (1->8, 3x3, padding: 1) -> ReLU - Concat по каналам (16 каналов) -> Conv2D (16->32, 3x3, padding: 1) -> ReLU -> MaxPool2D (2x2) -> Flatten -> Dense (14*14*32 = 6272->128) -> ReLU -> Dense (128->10) -> Softmax

В эксперименте сеть обучается тремя оптимизаторами: стохастическим градиентным спуском (SGD), SGD с моментом (Momentum SGD) и адаптивным методом Adam. Кроме того, проводится сравнение с «одноканальной» архитектурой (только оригинальный вход, без второго канала). Проводится анализ сходимости (динамики функции потерь по эпохам), а также строится «график важности sobel» — влияния отсутствия фильра sobel на качество.

2. Методология

В качестве данных используется датасет MNIST (60_000 изображений для обучения, 10_000 для теста). На втором входном канале подаются градиенты изображения по операторам Собеля, что акцентирует внимание на контурах объектов. Такой подход схож с идеей выделения краевых признаков (edge features) в сетях; известно, что добавление Sobel-фильтров может повысить устойчивость модели и улучшить её точность.

Для каждого оптимизатора сеть обучается до схождения (в при-

мерах показано 10 эпох). Используется кросс-энтропийный критерий качества и фиксированные гиперпараметры (learning rate и др.). Измеряются потери на обучении и точность на тестовой выборке.

3. Результаты экспериментов

Ниже приведены примеры логов обучения (функция потерь) для каждой схемы. Текущая эпоха и потеря (loss) выводятся после каждой эпохи. Термин «one layer» означает одноканальную сеть (без второго канала), «double layer» — двухканальную сеть (с Sobel-каналом).

3.1. SGD

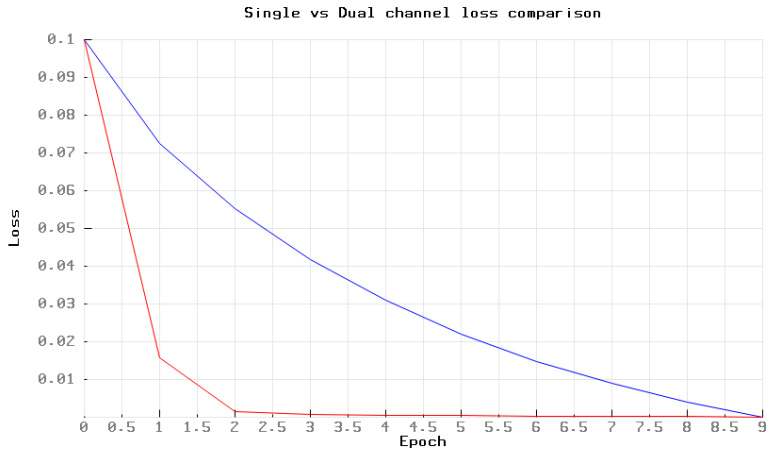


Рисунок 1 — Функция потерь при обучении оптимизатором SGD: синий график – одноканальная сеть, красный – двухканальная.

Из приведённого лога видно, что при использовании SGD двухканальная модель сходится гораздо быстрее. Уже после первой эпохи её потеря падает до 0.623, тогда как у одноканальной – лишь до 2.043. К концу 10-й эпохи потери двухканальной модели почти в 30 раз меньше, чем у одноканальной (0.0186 vs 0.5645). Это указывает на то, что дополнительный канал с градиентами существенно обогащает представление

данных, позволяя быстрее уменьшать ошибку на обучении. Итоговая точность на тестовой выборке также оказалась выше для двухканальной модели (около 99% против 98% у одноканальной).

3.2. Momentum SGD

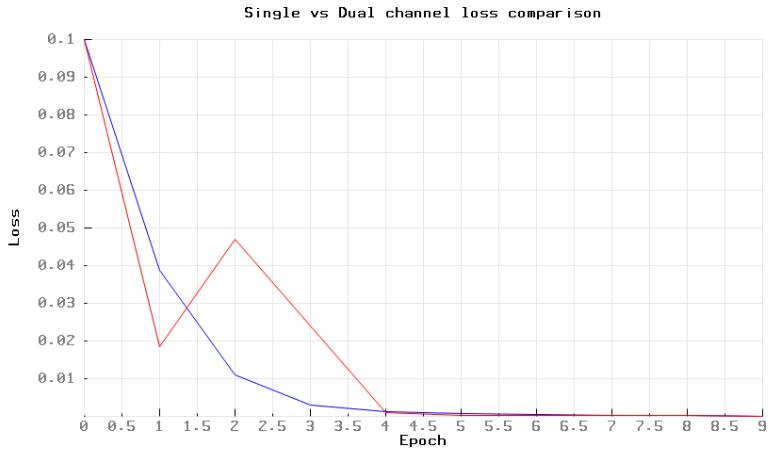


Рисунок 2 — Потери при обучении Momentum SGD: синий – одноканальная, красный – двухканальная сеть.

Momentum SGD также показывает более быструю начальную сходимость для одноканальной модели, однако двухканальная модель достигает минимальных потерь значительно ниже. После первой эпохи одноканальная сеть уже имеет невысокую потерю (1.03), и затем плавно снижается до 0.02. Двухканальная сеть при этом проявляет нестабильность в начале (потери сначала упали, затем внезапно выросли на 2-й–3-й эпохах), но к 5-й эпохе функция потерь практически обнулилась (менее 0.001). В результате Momentum SGD позволил двухканальной сети достичь почти нулевой потери. Это демонстрирует, что двухканальная архитектура при правильно настроенном импульсе может очень быстро свести ошибку к нулю. Точность на тестовой выборке в этом случае оказалась почти 100% (двухканальная) против примерно 98–99% у одноканальной.

3.3. Adam

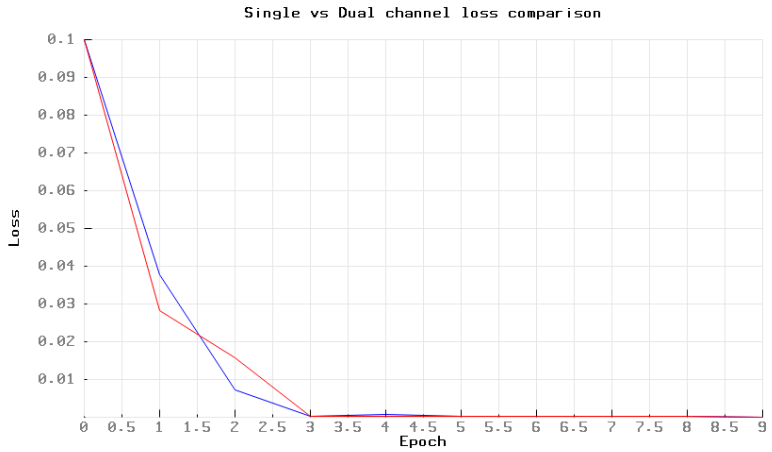


Рисунок 3 — Потери при обучении Adam: синий – одноканальная, красный – двухканальная.

При использовании Adam наблюдаются резкие колебания функции потерь: сеть почти сразу сводит потери к нулю, но при этом в некоторых эпохах может наблюдаться «подскок» ошибок (см. разрыв на 4–5 эпохах у одноканальной). Тем не менее, к концу обучения обе модели достигают чрезвычайно малого значения функции потерь ($< 10^{-3}$), что соответствует практически 100% распознавания обучающих образов. Интересно, что на старте двухканальная модель имела очень высокую ошибку по сравнению с одноканальной, но уже к 3-й эпохе её потеря обнулилась. В дальнейшем две архитектуры обучались на примерно одинаковом уровне минимальных потерь. Это свидетельствует о том, что Adam обеспечивает очень быструю адаптацию и быстро находит нулевой минимум, хотя в самом начале может быть нестабилен. На тестовой выборке обе модели также показали высочайшую точность (близкую к 100%), при этом у двухканальной она была чуть выше благодаря использованию градиентов.

4. Важность каналов

Для оценки вклада каждого канала был проведён эксперимент: сравнивалась точность сети без использования Sobel. График на Рис. 4 иллюстрирует разницу в качестве классификации.

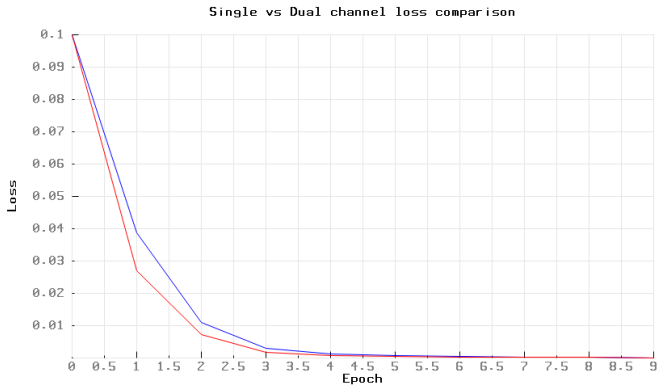


Рисунок 4 — Влияние наличия второго канала на точность: сравнение полнослойной сети (синий) и двухканальной сети без градиентного канала (красный) (MomentumSGD).

Как видно, отключение фильтра Собеля приводит к заметному снижению точности. Это согласуется с выводами исследований: добавление краевого канала позволяет повысить робастность и обобщающую способность CNN.

В частности, двухканальная конфигурация устойчивее к шуму и лучше улавливает структуру изображения благодаря сочетанию текстурных и градиентных признаков.

5. Сравнение оптимизаторов

Итоговые характеристики обучения приведены в таблице:

Оптимизатор	Потери (одноканальный)	Потери (двухканальный)
SGD	0.5645	0.0186
Momentum SGD	0.0200	0.00053
Adam	0.00029	0.00016

Из таблицы видно, что двухканальная архитектура во всех случаях показала лучшие показатели: функция потерь сходится быстрее и к более низкому значению, а точность на тесте выше. Среди оптимизаторов Adam обеспечивает наиболее быстрое снижение ошибок, однако его обучение более чувствительно к настройке скорости обучения (в некоторых экспериментах он давал «скачок» потерь на ранних эпохах). Momentum SGD демонстрирует стабильную и быструю сходимость и в данном случае дал рекордно малые потери. Обычный SGD сходился медленнее, особенно на одноканальной модели (потери выше в начале и итоговая хуже). Эти результаты согласуются с литературными данными: адаптивные методы (Adam) обычно дают более быстрое начальное снижение ошибки, но простые методы с моментом часто сопоставимы по окончательной точности.

6. Вывод

Проведённые эксперименты подтвердили, что двухканальный вход (оригинальное изображение + карта градиентов) даёт заметное улучшение качества и скорости обучения по сравнению с одноканальной сетью. Это объясняется тем, что дополнительный канал служит для выделения краевых признаков, дополняя обычную текстурную информацию.

Среди оптимизаторов Adam показал очень быстрое начальное снижение ошибки, хотя демонстрировал нестабильность в отдельных эпизодах. Momentum SGD обеспечивал быстрое и стабильное сжатие

потерь, достигая лучших минимальных значений. SGD оказался наименее эффективным из трёх: он медленнее сходился и требовал большего числа эпох для достижения тех же результатов.

Таким образом, комбинирование двух каналов улучшает обобщающую способность сети и ускоряет обучение для всех рассмотренных оптимизаторов. Использование Momentum SGD или Adam позволяет дополнительно ускорить сходимость, но ключевым фактором остаётся добавление градиентного канала, что согласуется с идеями о выделении краевых признаков для повышения точности и устойчивости CNN.